

Le mémoire, concept par concept

Ce que chaque outil résout, comment il marche, et la phrase qui l'explique en trente secondes

Kélian Kaddouri

3 août 2026

À quoi sert ce document. Le mémoire empile une vingtaine d'outils, chacun choisi pour une raison précise, et il est facile de les manipuler correctement sans savoir les *défendre*. Chaque section suit le même gabarit : le problème que l'outil résout, l'idée en langage courant, la formule, ce que ça donne dans notre cas, la phrase à dire à voix haute quand on vous interroge, et le piège à éviter.

La phrase encadrée en vert est le livrable de chaque section. Si vous ne retenez qu'elle, vous tenez l'oral.

Le schéma d'ensemble se trouve dans le fichier `schema_modele.pdf` : il montre comment ces vingt-sept briques s'enchaînent, de la donnée brute au capital.

Table des matières

I. D'où viennent les nombres	3
1 Les trois sources, et ce que chacune peut dire	3
2 La conversion Jacobs	3
II. Combien d'incidents par an	4
3 Le processus de Poisson, et pourquoi il ne suffit pas	4
4 La surdispersion et la négative binomiale	4
5 Pourquoi pas un processus de Hawkes	5
III. Combien coûte un incident	5
6 Pourquoi la théorie des valeurs extrêmes	5
7 Les deux théorèmes fondateurs	5
8 La méthode des excès et la loi de Pareto généralisée	6
9 Le choix du seuil	6
IV. Comment les pertes s'additionnent	7
10 Le modèle collectif	7
11 VaR, TVaR, et pourquoi le SCR est une VaR	7

V. Comment un problème en entraîne un autre	7
12 La matrice de contagion et sa normalisation	7
13 L'inverse de Leontief et la sous-criticité	8
14 Le seuil de déclenchement, et le rôle de la loi normale	8
15 Les copules et la dépendance de queue	9
VI. Ce qu'on ne peut pas savoir, et pourquoi	9
16 La décomposition $W = S + A$	9
17 Le renversement du temps et la fluctuation martingale	9
18 Le test placebo	10
19 La production d'entropie	11
20 z scalaire ou z par paire	11
21 L'identification partielle	11
22 Pourquoi A compte quand même	12
VII. À quel point on y croit	12
23 Le bootstrap	12
24 Les tests d'adéquation	12
25 Les trois étages d'incertitude	13
26 VaR prédictive et VaR robuste	13
VIII. Les outils annexes	14
27 Le kappa de Cohen	14
28 La valeur d'information	14
29 Le bayésien conjugué	15
Annexe : les vingt nombres à connaître	16

I. D'où viennent les nombres

1 Les trois sources, et ce que chacune peut dire

Le problème. Pour chiffrer un capital, il faut trois choses : combien d'incidents par an, combien coûte un incident, et comment les incidents s'enchaînent. Aucune source publique ne porte les trois.

L'idée. On ne cherche pas *la* bonne base, on répartit les questions entre les sources selon ce que chacune peut porter, et on déclare ce qui manque.

Chez nous. Trois sources, trois rôles disjoints.

- **SAS OpRisk Global Data** : pertes opérationnelles en dollars, catégories de Bâle, 4 329 transitions annuelles consécutives. Elle porte le **niveau** de sévérité et le volume. Son pas est annuel, ce qui efface l'ordre des événements.
- **Privacy Rights Clearinghouse (PRC)** : 15 053 incidents, mais exprimés en *nombre d'enregistrements compromis*, pas en euros. Elle sert d'**axe de sensibilité** après conversion.
- **Sept rapports post-incident** : peu de volume, mais une enquête y reconstitue la *séquence* des défaillances. C'est la seule source qui porte l'**ordre**.

À dire à voix haute. *Aucune base ne dit tout. OpRisk donne le niveau et le volume mais pas l'ordre, PRC donne du volume mais pas d'euros, et les rapports d'enquête donnent l'ordre mais pas le volume. Je les utilise pour ce que chacune peut porter, et je dis explicitement ce qui reste absent.*

Le piège. Ne jamais laisser croire qu'on a *ré* une base de données DORA *z*. Elle n'existe pas. Le règlement met en place le reporting qui la produira, et c'est justement l'objet de la recommandation finale du mémoire.

2 La conversion Jacobs

Le problème. PRC compte des enregistrements compromis, pas des euros. Il faut passer de l'un à l'autre.

L'idée. Une régression publiée établit, sur un échantillon d'incidents dont on connaît à la fois le nombre d'enregistrements et le coût, une relation log-log entre les deux.

La formule. $\ln L = 7,68 + 0,76 \ln X + \varepsilon$, où X est le nombre d'enregistrements et L la perte en dollars. Le résidu a un écart-type de 0,523, et $R^2 = 0,512$.

Chez nous. L'exposant $0,76 < 1$ dit que le coût croît *moins vite* que le nombre d'enregistrements : un incident dix fois plus gros ne coûte pas dix fois plus cher, mais environ six fois. Il y a un coût fixe important dans tout incident.

À dire à voix haute. *Jacobs n'est pas un lien fréquence-sévérité, c'est une conversion de sévérité seule : elle transforme un nombre d'enregistrements en montant. Et mon capital principal n'en dépend pas, il est calculé sur OpRisk, qui est déjà en dollars.*

Le piège. Le modèle traitait cette conversion comme *exacte*, en ignorant le résidu, ce qui écrasait la dispersion de sévérité. En réinjectant le résidu, le niveau monte de 7 % et la queue s'épaissit (ξ passe de 1,03 à 1,07), mais la largeur relative de l'intervalle ne bouge pas. À dire spontanément : la conversion était traitée comme sûre alors qu'elle ne l'est pas.

II. Combien d'incidents par an

3 Le processus de Poisson, et pourquoi il ne suffit pas

Le problème. Modéliser un nombre d'événements par an, sans savoir quand ils tombent.

L'idée. Si les événements arrivent indépendamment, à un rythme constant, et jamais deux exactement en même temps, alors leur nombre annuel suit une loi de Poisson. C'est le modèle de comptage par défaut, et il n'a qu'un paramètre.

La formule. $\mathbb{P}(N = k) = e^{-\lambda} \lambda^k / k!$, avec la propriété caractéristique

$$\mathbb{E}[N] = \text{Var}(N) = \lambda.$$

Moyenne et variance sont *égales*. C'est à la fois sa force et sa faiblesse.

Chez nous. Cette égalité est testable, et elle est rejetée massivement. Sur 14 944 cellules entité-année, un test du rapport de vraisemblance donne $p \approx 10^{-30}$. Autrement dit : la probabilité d'observer nos données si Poisson était vrai est de l'ordre d'un sur 10^{30} .

À dire à voix haute. *Poisson impose que la variance égale la moyenne. Dans les données, la variance est neuf fois la moyenne. Ce n'est pas une nuance, c'est un rejet à 10^{-30} , donc j'ai changé de loi.*

Le piège. Ne pas dire que Poisson sous-estime le risque. Poisson donne la *bonne* moyenne, il se trompe sur la *dispersion*, donc sur la queue. Le SCR est un quantile extrême : c'est la dispersion qui le fait, pas la moyenne.

4 La surdispersion et la négative binomiale

Le problème. Les données montrent beaucoup plus de variabilité que Poisson n'en autorise. Pourquoi, et comment en tenir compte ?

L'idée. Parce que le rythme lui-même varie. Certaines années sont plus exposées que d'autres, certaines entités plus que d'autres. On rend donc λ *aléatoire* au lieu de le fixer. Un mélange de Poisson par une loi Gamma donne exactement la négative binomiale.

La formule. Si $N | \Lambda \sim \mathcal{P}(\Lambda)$ et $\Lambda \sim \text{Gamma}$, alors N est négative binomiale et

$$\mathbb{E}[N] = \lambda, \quad \text{Var}(N) = \varphi \lambda, \quad \varphi > 1.$$

Le facteur φ est la **surdispersion** : le rapport variance sur moyenne.

Chez nous. $\varphi = 9,2$. La variance vaut neuf fois la moyenne. Trois mesures de cette surdispersion coexistaient dans le modèle sans avoir jamais été confrontées : deux d'entre elles se sont révélées être la même quantité vue de deux angles, elles coïncident à 5 %. À variance égale, la *forme* du mélange (Gamma ou lognormale) déplace encore la queue de 11 %.

À dire à voix haute. *La négative binomiale, c'est Poisson dont le rythme est lui-même incertain. Concrètement, certaines années sont plus exposées que d'autres, et ce sont ces années-là qui font le capital.*

Le piège. Le changement de loi de comptage **ne déplace pas la moyenne**, il déplace la VaR. C'est logique : $\mathbb{E}[N] = \lambda$ dans les trois lois testées. Sur la série détrendée, la surdispersion est *trois fois plus faible* que celle retenue : le calage est conservateur, pas calibré, et il faut le dire soi-même.

5 Pourquoi pas un processus de Hawkes

Le problème. Un processus auto-excité, où chaque événement augmente temporairement la probabilité du suivant, serait un candidat naturel pour de la contagion.

L'idée. Hawkes modélise la contagion *dans le temps* : un incident aujourd'hui rend un autre incident plus probable demain. Notre cascade modélise la contagion *entre domaines* : un incident sur un pilier rend un incident plus probable sur un autre pilier. Ce ne sont pas les mêmes axes.

Chez nous. L'estimation d'un noyau d'excitation demande des dates fines. Nos données sont annuelles : le noyau serait entièrement non identifié, exactement comme la direction. La littérature cyber sur Hawkes (Boumezoued, Hillairet) travaille sur des données horodatées finement, que nous n'avons pas.

À dire à voix haute. *Hawkes décrit la contagion dans le temps, ma cascade décrit la contagion entre domaines. Les deux sont compatibles, mais Hawkes demande des dates fines que mes données n'ont pas. Je ne le contredis pas, je ne peux simplement pas le calibrer.*

Le piège. Ne pas présenter le rejet de Hawkes comme une critique de cette littérature. La formulation qui marche est *à cela ne contredit pas, cela ne s'applique pas à ma donnée z*.

III. Combien coûte un incident

6 Pourquoi la théorie des valeurs extrêmes

Le problème. Le SCR est un quantile à 99,5 %. On veut donc décrire précisément la région où l'on a le moins d'observations. Ajuster une loi sur l'ensemble des données optimise l'ajustement là où il y a le plus de points, c'est-à-dire au *centre*, exactement là où l'on s'en moque.

L'idée. On abandonne l'idée d'une loi unique pour tout. On modélise *seulement* la queue, avec une famille dont on peut démontrer qu'elle est la seule limite possible.

À dire à voix haute. *Une loi ajustée sur toutes les données est calée sur le centre, or je n'ai besoin que de la queue. La théorie des valeurs extrêmes dit quelle famille de lois est la seule possible tout au bout, et je n'ajuste que celle-là.*

7 Les deux théorèmes fondateurs

L'idée. Deux résultats, structurés exactement comme le théorème central limite : ils disent qu'une *seule* famille peut apparaître à la limite, quelle que soit la loi de départ.

La formule. Fisher-Tippett-Gnedenko. Si le maximum renormalisé de n variables indépendantes converge en loi, la limite ne peut être que la loi des valeurs extrêmes généralisée :

$$G_\xi(x) = \exp\left\{- (1 + \xi x)^{-1/\xi}\right\}, \quad 1 + \xi x > 0.$$

Pickands-Balkema-de Haan. De façon équivalente, la loi des *excès* au-dessus d'un seuil u converge, quand u monte vers le point terminal, vers la loi de Pareto généralisée :

$$\mathbb{P}(X - u \leq y \mid X > u) \longrightarrow 1 - \left(1 + \frac{\xi y}{\sigma}\right)^{-1/\xi}.$$

Chez nous. C'est le second qu'on utilise, parce qu'il exploite *tous* les dépassements de seuil et pas seulement le maximum de chaque bloc. On perd beaucoup moins d'information.

À dire à voix haute. *C'est le même genre de résultat que le théorème central limite. Là où le TCL dit que les moyennes tendent vers une gaussienne quelle que soit la loi de départ, ces deux théorèmes disent que les extrêmes tendent vers une seule famille. Je n'ai donc pas choisi la loi de queue, elle est imposée.*

Le piège. Ces théorèmes sont *asymptotiques*. Ils ne garantissent pas que la GPD est correcte à un seuil fini : ils garantissent qu'aucune autre famille ne peut l'être à la limite. C'est plus faible, il faut le dire, et c'est pourquoi on teste l'adéquation.

8 La méthode des excès et la loi de Pareto généralisée

L'idée. On fixe un seuil u . En dessous, on garde la distribution empirique telle quelle. Au dessus, on ajuste une GPD. La loi obtenue est dite *recollée* (spliced).

La formule. La fonction de survie s'écrit, pour $x > u$:

$$\mathbb{P}(X > x) = p_u \left(1 + \frac{\xi(x-u)}{\sigma} \right)^{-1/\xi}, \quad p_u = \mathbb{P}(X > u).$$

Chez nous. $\xi = 0,60$ sur OpRisk, $\xi = 1,03$ sur PRC. Le paramètre ξ est l'**indice de queue**, et il commande tout :

- $\xi < 1/2$: variance finie ;
- $1/2 < \xi < 1$: variance *infinie*, moyenne finie ;
- $\xi > 1$: moyenne elle-même infinie.

Notre $\xi = 1,03$ sur PRC dépasse 1 : la moyenne théorique n'existe pas. Ce n'est pas une erreur de calcul, c'est une propriété du cyber.

À dire à voix haute. *L'indice de queue mesure à quel point les catastrophes dominent. Au dessus de un, la moyenne théorique n'existe même plus : c'est un domaine où un seul sinistre peut peser plus que tous les autres réunis. C'est exactement ce qu'on observe en cyber.*

Le piège. Avec ξ proche de 1, la moyenne empirique n'est pas un estimateur stable et les intervalles de confiance sont larges par nature. Ne jamais annoncer un SCR ponctuel sans sa bande dans ce régime.

9 Le choix du seuil

Le problème. Le seuil u arbitre entre biais et variance : trop bas, on inclut le corps de la distribution et l'approximation GPD est fautive ; trop haut, il reste trop peu de points et l'estimation devient bruitée.

L'idée. On ne le choisit pas au hasard, on le lit sur deux graphiques de diagnostic.

La formule. Vie résiduelle moyenne. Pour une GPD, la fonction $e(u) = \mathbb{E}[X - u \mid X > u]$ est *linéaire* en u . On choisit u au début de la zone linéaire. **Graphique de Hill.** On trace $\hat{\xi}$ en fonction de u et on cherche un plateau.

Chez nous. Seuil retenu $u = 4,176$ M€ sur PRC, avec $p_u = 0,150$, donc 15 % des pertes dépassent le seuil. Les deux diagnostics concordent.

À dire à voix haute. *Le seuil se lit sur deux graphiques : la vie résiduelle moyenne doit devenir droite, et l'indice de queue doit se stabiliser. Les deux disent la même chose ici, et c'est ce qui rend le choix défendable plutôt qu'arbitraire.*

IV. Comment les pertes s'additionnent

10 Le modèle collectif

L'idée. On ne modélise pas la perte annuelle directement. On modélise séparément *combien* d'incidents et *combien coûte* chacun, puis on somme. C'est le cadre standard en actuariat non-vie.

La formule.

$$L = \sum_{i=1}^N X_i,$$

avec N le nombre d'incidents (fréquence) et X_i leurs coûts (sévérité), les X_i indépendants de N et entre eux.

Chez nous. 10^5 années simulées par Monte-Carlo. On ne cherche pas de formule fermée pour la loi de L : avec une queue lourde et une cascade, il n'y en a pas.

À dire à voix haute. *Je sépare deux questions qui n'ont rien à voir : combien d'incidents par an, et combien coûte un incident. Chacune se calibre sur ses propres données, et la perte annuelle est leur somme.*

Le piège. L'hypothèse d'indépendance entre N et les X_i est une hypothèse, pas un fait. Dans une crise, il y a plus d'incidents *et* ils sont plus chers. C'est exactement ce que la cascade réintroduit.

11 VaR, TVaR, et pourquoi le SCR est une VaR

L'idée. La VaR à 99,5 % est le montant qu'on ne dépasse que dans une année sur deux cents. La TVaR est la moyenne des pertes *au-delà* de ce seuil.

La formule.

$$\text{VaR}_\alpha(L) = \inf\{x : \mathbb{P}(L \leq x) \geq \alpha\}, \quad \text{TVaR}_\alpha(L) = \mathbb{E}[L \mid L > \text{VaR}_\alpha(L)].$$

Chez nous. Solvabilité II impose la VaR à 99,5 % à horizon un an. On ne choisit pas cette mesure, elle est réglementaire, et c'est un point à faire valoir quand on nous reproche d'utiliser un quantile.

À dire à voix haute. *Le SCR, c'est la perte qu'on ne dépasse qu'une année sur deux cents. Ce n'est pas mon choix de mesure, c'est celui de Solvabilité II.*

Le piège. La VaR n'est pas sous-additive : la VaR d'une somme peut dépasser la somme des VaR. La TVaR, elle, est cohérente. Si on nous interroge sur ce point : *si* je rapporte les deux, et la TVaR est effectivement la mesure la plus saine, mais le capital réglementaire se calcule en VaR *si*.

V. Comment un problème en entraîne un autre

12 La matrice de contagion et sa normalisation

Le problème. On veut dire *si* un problème sur le pilier j aggrave le pilier k *si*, avec une intensité. Mais si on met des coefficients au hasard, la cascade peut exploser.

L'idée. On part du jugement dirigé (la matrice TRANS du classeur), et on la renormalise pour garantir mathématiquement que la propagation s'éteint.

La formule.

$$W = g \frac{\text{TRANS}}{\max_j \sum_k \text{TRANS}_{jk}}, \quad g = 0,90,$$

ce qui garantit $\rho(W) \leq g < 1$, où ρ est le rayon spectral (la plus grande valeur propre en module).

Chez nous. Le facteur g est un curseur de propagation : $g = 0$ signifie aucune contagion, $g \rightarrow 1$ signifie une cascade au bord de l'explosion. On le fixe à 0,90, ce qui est volontairement élevé.

À dire à voix haute. *La normalisation garantit que la cascade s'éteint. Sans elle, un choc pourrait s'amplifier indéfiniment en tournant en boucle entre les piliers, et le capital serait infini.*

Le piège. $g = 0,90$ est un *choix*, pas une mesure. À dire ainsi : n'est-ce pas un paramètre de sévérité de scénario, et je montre le résultat pour $g = 0$ et $g = 0,90$ afin qu'on voie ce qu'il porte z.

13 L'inverse de Leontief et la sous-criticité

L'idée. Le choc initial se propage, ce qu'il déclenche se propage à son tour, et ainsi de suite. La somme de tous les tours est une série géométrique matricielle.

La formule.

$$(I - W)^{-1} = I + W + W^2 + W^3 + \dots$$

Cette série converge *si et seulement si* $\rho(W) < 1$. Le terme I est le choc initial, W ce qu'il déclenche directement, W^2 ce que cela déclenche à son tour.

Chez nous. L'objet vient de l'économie (Leontief, tableaux entrées-sorties) : la même algèbre décrit comment une commande dans un secteur en génère dans les autres.

À dire à voix haute. *C'est la même formule que les tableaux entrées-sorties en économie. Le premier terme est le choc direct, le deuxième ce qu'il déclenche, le troisième ce que cela déclenche à son tour. La condition de convergence est exactement la condition pour que la cascade s'éteigne.*

Le piège. Le passage à W^2 est celui où la *direction* commence à compter, alors qu'elle ne compte pas dans W seul si on ne regarde que les co-occurrences. C'est le point technique le plus important du mémoire, voir la section 22.

14 Le seuil de déclenchement, et le rôle de la loi normale

Le problème. À partir de quand un pilier bascule ? Il faut un mécanisme, pas seulement une probabilité.

L'idée. On suppose une variable latente X_j qui mesure la fragilité du pilier j , et le pilier bascule quand elle franchit un seuil. C'est le mécanisme de Merton, repris par Vasicek pour le risque de crédit.

La formule. Le pilier j bascule quand

$$X_j \geq K_j = F^{-1}(1 - p_j),$$

où p_j est sa probabilité marginale de basculement et F la fonction de répartition de la latente.

Chez nous. $K_4 = 1,033$ pour le pilier prestataires.

À dire à voix haute. *Il y a deux questions derrière le mot seuil, et il ne faut pas les mélanger. Pour savoir quand un pilier bascule tout seul, la loi normale est inoffensive : elle ne sert que d'unité de mesure, la vraie queue lourde est dans la sévérité, pas ici. Pour savoir combien de piliers basculent ensemble, c'est autre chose, et là le gaussien pose un vrai problème.*

Le piège. Le choix de la loi de la latente est une *normalisation* pour la marge : n'importe quelle loi continue donnerait la même probabilité marginale, seul le seuil change de valeur. Ce n'est pas vrai pour la dépendance. Confondre les deux est l'erreur classique.

15 Les copules et la dépendance de queue

Le problème. Comment plusieurs piliers basculent-ils *ensemble*? La probabilité marginale de chacun ne suffit pas à le dire.

L'idée. Une copule sépare les marges de la structure de dépendance. On peut garder les mêmes marges et changer complètement la façon dont les événements extrêmes se coordonnent.

La formule. Le coefficient de **dépendance de queue supérieure** mesure la co-occurrence extrême :

$$\lambda_U = \lim_{q \rightarrow 1^-} \mathbb{P}(U_2 > q \mid U_1 > q).$$

Pour la copule gaussienne, $\lambda_U = 0$ dès que la corrélation est < 1 . Pour la copule de Gumbel de paramètre θ ,

$$\lambda_U = 2 - 2^{1/\theta}.$$

Chez nous. Avec $\theta = 1,8$, on a $\lambda_U = 0,53$. À τ de Kendall *égal*, la gaussienne donne 0 et Gumbel 0,53. La probabilité que les cinq piliers basculent ensemble passe de 0,17 à 0,39 selon la copule retenue. On encadre au lieu de trancher : plancher gaussien, plafond de Gumbel.

À dire à voix haute. Une dépendance gaussienne a une propriété gênante : dans les extrêmes, elle prédit que les choses se découpent. C'est le contraire de ce qu'on observe en crise. Donc je n'ai pas tranché entre les deux, j'ai encadré, et l'écart entre le plancher et le plafond est un résultat en soi.

Le piège. Deux copules peuvent avoir le même τ de Kendall, donc la même dépendance $\acute{a}$ moyenne $\acute{z}$, et des comportements extrêmes opposés. Comparer deux copules par leur corrélation ne dit rien sur la queue.

VI. Ce qu'on ne peut pas savoir, et pourquoi

16 La décomposition $W = S + A$

L'idée. Toute matrice se coupe de manière unique en une partie symétrique et une partie antisymétrique. La première dit *qui est lié à qui*, la seconde dit *dans quel sens*.

La formule.

$$S = \frac{1}{2}(W + W^\top), \quad A = \frac{1}{2}(W - W^\top), \quad W = S + A.$$

Les deux parties sont **orthogonales** : $\langle S, A \rangle = 0$, d'où un Pythagore $\|W\|^2 = \|S\|^2 + \|A\|^2$.

Chez nous. $\|A\|/\|W\| = 40,7\%$. La direction représente 40 % de la matrice, ce n'est pas un détail.

À dire à voix haute. On coupe la matrice en deux : une partie qui dit quels piliers sont liés, et une partie qui dit dans quel sens. Les deux sont orthogonales, ce qui veut dire que connaître l'intensité n'apprend rien sur la direction.

Le piège. La décomposition propre porte sur le *flux stationnaire* $\pi_j P_{jk}$, pas sur la matrice de transition brute. Notre $S = (W + W^\top)/2$ en est le cas où π est uniforme, et l'écart mesuré est de 0,069, donc faible. Le dire soi-même met à l'abri.

17 Le renversement du temps et la fluctuation martingale

Le problème. Pourquoi n'arrive-t-on pas à mesurer A ? Et est-ce une limite de méthode ou une limite de principe?

L'idée. Passer le film à l'envers. La partie symétrique ne change pas, la partie antisymétrique s'inverse. Et la fluctuation d'un processus, une fois la tendance retranchée, ne dépend que de la première.

La formule. La chaîne renversée a pour flux $F^* = F^\top = S - A$. Et pour toute fonction test f , l'intensité de la fluctuation vaut

$$\mathbb{E}_\pi[\Gamma(f, f)] = \sum_{j,k} S_{jk} (f(k) - f(j))^2,$$

la partie A y contribuant exactement zéro. La démonstration tient en une ligne : $(f(k) - f(j))^2$ est symétrique en (j, k) , A est antisymétrique, les termes (j, k) et (k, j) se compensent.

Chez nous. Vérifié sur 2 000 fonctions test tirées au hasard : écart maximal $1,8 \times 10^{-15}$, c'est-à-dire zéro numérique.

À dire à voix haute. Renverser le temps laisse la partie symétrique intacte et retourne le signe de la partie directionnelle. Or la fluctuation d'un processus, sa partie martingale, ne dépend que de la symétrie. Donc une donnée annuelle, qui ne garde pas l'ordre, ne peut mathématiquement pas voir la direction.

Le piège. Ne pas dire que W est une chaîne de Markov. C'est un noyau de contagion : on emprunte l'algèbre de la réversibilité comme cadre de lecture, on n'ajoute pas une hypothèse.

18 Le test placebo

Le problème. Même des données sans aucune direction produisent un déséquilibre, par simple fluctuation d'échantillonnage. Observer un déséquilibre ne prouve donc rien tant qu'on ne sait pas ce que le hasard produit tout seul.

L'idée. On fabrique une version des données dont la direction a été **détruite volontairement**, tout le reste étant conservé, et on compare. C'est l'essai clinique : si le médicament ne fait pas mieux que la pilule vide, il ne fait rien.

La formule. On mesure l'asymétrie de la matrice de transitions comptées :

$$\mathcal{A}(M) = \frac{\|M - M^\top\|_1}{2} = \frac{1}{2} \sum_{j,k} |M_{jk} - M_{kj}|,$$

c'est-à-dire le surplus de transitions d'un sens sur l'autre, sommé sur toutes les paires. Puis on **permute les années à l'intérieur de chaque entité** : l'ensemble des catégories touchées chaque année est conservé, seul l'ordre est détruit. On recompte, on recalcule, et on compare :

$$z = \frac{\mathcal{A}(M_{\text{obs}}) - \overline{\mathcal{A}^{\text{null}}}}{\widehat{s}(\mathcal{A}^{\text{null}})}.$$

Chez nous.

Source	observée	sous placebo	z	Verdict
OpRisk, pas annuel	119	128 ± 27	-0,33	aucun signal
7 post-mortems	même protocole		+3,93	signal net

Sur OpRisk, l'observé est *sous* la moyenne du bruit. Un test binomial par paire le confirme : aucune paire ne survit à la correction de Bonferroni.

À dire à voix haute. Je voulais savoir si la direction que je crois voir est réelle. Le problème, c'est que même des données au hasard produisent un déséquilibre. Alors j'ai pris mes données, j'ai détruit l'ordre en gardant tout le reste, et j'ai comparé. Mes vraies données font 119, le hasard fait 128 : elles font moins bien que le hasard. Puis j'ai refait exactement le même test sur les sept rapports d'enquête, et là le signal apparaît nettement. Même test, autre source, résultat opposé : le problème venait de la donnée, pas de la méthode.

Le piège. Trois choses à ne pas dire. **(i)** Le test du $\hat{z}$ temps inversé est *dégénéré* sur un comptage : renverser la chronologie donne $M^\top$ par construction, donc une corrélation de -1 quel que soit le contenu. Il ne prouve rien. **(ii)** Un test non rejeté n'est pas une preuve d'absence : la donnée est *compatible* avec l'absence de direction. **(iii)** Sur les post-mortems, le test établit la *cohérence* du codage, pas son *exogénéité* : le biais de narration des rapports d'enquête n'est pas levé par le calcul.

19 La production d'entropie

L'idée. Un seul nombre qui dit à quel point le processus est dirigé, et qui a une interprétation exacte : à quel point le film à l'endroit est distinguable du film à l'envers.

La formule.

$$\sigma = \sum_{j < k} 2A_{jk} \ln \frac{S_{jk} + A_{jk}}{S_{jk} - A_{jk}} \geq 0,$$

nulle si et seulement si $A = 0$. Elle est aussi le taux d'entropie relative entre la loi de la trajectoire lue à l'endroit et celle lue à l'envers.

Chez nous. $\sigma = 0,0700$ pour la chaîne posée, 5×10^{-33} après symétrisation. **Et le résultat qui compte :** chaque terme de la somme est *pair* en A_{jk} , donc σ ne dépend que des *amplitudes*, pas des signes. Vérifié numériquement : les 1024 sommets de l'ensemble admissible ont tous *exactement* la même σ , amplitude $0,0 \times 10^0$, alors que le capital y varie de 27 %.

À dire à voix haute. *La production d'entropie mesure à quel point on peut distinguer le film à l'endroit du film à l'envers. Si elle est nulle, personne ne peut dire dans quel sens le temps coule. Mais attention : elle ne voit que la quantité de direction, jamais son sens. Les mille vingt-quatre configurations ont toutes la même production d'entropie, et pourtant elles étalent le capital d'un quart.*

Le piège. Conséquence à tirer : ce n'est pas σ qu'il faut chercher à estimer, ce sont les *signes*, un par un. C'est ce qui justifie que la valeur d'information se hiérarchise par paire et non globalement.

20 z scalaire ou z par paire

Le problème. L'écriture $P = S + zA$ est ambiguë tant qu'on n'a pas dit si z est un nombre ou dix.

La formule. Lecture globale : $z \in [-1, 1]$ règle l'*intensité* d'un motif de direction fixé. Un seul degré de liberté. Elle ne peut pas changer quel pilier précède quel autre. **Lecture par paire,** celle du mémoire :

$$A_{jk} = z_{jk} t S_{jk}, \quad z_{jk} \in [-1, 1], \quad j < k,$$

soit **dix degrés de liberté**. Le paramètre t est l'amplitude maximale d'asymétrie, les z_{jk} portent chacun un sens indépendant.

Chez nous. Les $2^{10} = 1024$ sommets sont exactement les configurations $z_{jk} = \pm 1$. La contrainte de positivité du flux impose $|A_{jk}| \leq S_{jk}$, donc $t \leq 1$; $t = 1$ est l'ignorance totale.

À dire à voix haute. *Un z global ne fait que renforcer ou affaiblir un ordre déjà choisi. Ce qu'il me faut, c'est un curseur par paire, parce que c'est le sens de chaque lien que je ne connais pas, pas son intensité globale.*

21 L'identification partielle

L'idée. Quand un paramètre n'est pas identifiable, il reste deux attitudes : le poser arbitrairement et faire semblant, ou énumérer tout ce qu'il pourrait être et rapporter l'intervalle qui en résulte. La seconde est l'identification partielle, au sens de Manski.

La formule. On définit l'ensemble admissible

$$\mathcal{W} = \{ W = S + A : |A_{jk}| \leq t S_{jk} \},$$

et l'on rapporte $[\inf_{\mathcal{W}} \text{SCR}, \sup_{\mathcal{W}} \text{SCR}]$ au lieu d'un point.

Chez nous. Socle sans contagion 5 275 M€. Avec contagion et ignorance totale, capital borné dans $[6\,858; 8\,697]$ M€. L'énumération porte sur 1024 sommets, et un audit sur 3 000 points intérieurs a confirmé qu'aucun ne sort de l'enveloppe des sommets.

À dire à voix haute. *Je ne prétends pas connaître la direction, donc je ne donne pas un chiffre, je donne une fourchette. Ce n'est pas de la prudence, c'est la seule réponse possible : une grandeur qui compte pour le résultat et qui est invisible dans mes données.*

Le piège. L'atteinte des extrêmes aux sommets est une *propriété vérifiée numériquement*, pas un théorème démontré. C'est déclaré comme telle dans le mémoire.

22 Pourquoi A compte quand même

Le problème. Si A est invisible dans la donnée, pourquoi s'en soucier ?

La formule. Parce que le capital passe par $(I - W)^{-1} = I + W + W^2 + \dots$, et dès le terme quadratique $W^2 = S^2 + SA + AS + A^2$ fait apparaître A . En prenant la trace :

$$\text{tr}(W^2) = \|S\|^2 - \|A\|^2.$$

Le signe moins vient de l'antisymétrie : $A^\top = -A$ implique $A^2 = -AA^\top$.

À dire à voix haute. *La direction est invisible au premier ordre mais elle apparaît dès qu'on met la matrice au carré, et le calcul du capital passe par là. Une grandeur qui compte pour la réponse et qui est absente de la donnée : c'est la définition exacte d'une identification partielle.*

VII. À quel point on y croit

23 Le bootstrap

L'idée. On ne connaît pas la loi de l'estimateur. Alors on la fabrique : on rééchantillonne les données avec remise, on réestime à chaque fois, et la dispersion des estimations obtenues approche la dispersion vraie.

Chez nous. Le seul intervalle de confiance bootstrap sur le quantile à 99,5 % vaut un **facteur** 2,6 entre ses deux bouts. Le bootstrap est aussi utilisé en version *paramétrique* pour les tests d'adéquation : on simule sous la loi ajustée pour obtenir la loi de la statistique de test.

À dire à voix haute. *Le bootstrap fabrique la loi de mon estimateur en rééchantillonnant mes propres données. Et le résultat est brutal : rien que cette incertitude-là vaut un facteur deux et demi sur le capital.*

Le piège. Le bootstrap capture l'incertitude *de paramètre* à modèle fixé. Il ne dit rien sur le risque que le modèle lui-même soit faux, qui est bien plus grand ici (facteur 5,5).

24 Les tests d'adéquation

L'idée. Une loi ajustée peut être fausse. On teste la distance entre la loi ajustée et les données, et on regarde si cette distance est anormalement grande.

La formule. Kolmogorov-Smirnov mesure l'écart maximal entre les fonctions de répartition. Anderson-Darling pondère ce même écart pour donner davantage de poids aux *queues*, ce qui est exactement la région qui nous intéresse.

Chez nous. $p = 0,87$ pour les deux, par bootstrap paramétrique. La couverture des intervalles de confiance à 90 % est de 86 %, donc légèrement optimiste mais acceptable. La négative binomiale bat le Poisson avec $p \approx 10^{-30}$.

À dire à voix haute. *Les tests ne rejettent pas, avec une valeur p de 0,87. Attention à ce que cela veut dire : les formes sont validées, mais c'est le niveau qui reste une bande.*

Le piège. Les valeurs critiques tabulées de KS et AD sont fausses quand les paramètres sont *estimés* sur les mêmes données. Il faut passer par un bootstrap paramétrique, ce que nous faisons, et il faut le dire, parce que beaucoup de mémoires ne le font pas.

25 Les trois étages d'incertitude

L'idée. L'incertitude ne se réduit pas à l'intervalle de confiance. Elle a trois sources qui se cumulent et dont les tailles n'ont rien à voir.

Chez nous.

Étage	Nature	Facteur
Paramètre	les données sont finies (bootstrap)	2,6
Identification	la direction n'est pas mesurable (bornes)	27 % de bande
Modèle	la famille de loi elle-même est un choix	5,5
dont la structure de dépendance seule		1,8

À dire à voix haute. *Le choix de la famille de queue déplace le résultat d'un facteur cinq et demi, soit deux fois plus que l'incertitude statistique. Autrement dit, l'essentiel du risque n'est pas dans mes données, il est dans mes hypothèses. Mais le résultat qui tient est ailleurs : le niveau bouge dans la bande, l'ordre des piliers ne bouge pas.*

Le piège. Cette section peut donner l'impression que rien ne tient. Toujours l'enchaîner immédiatement avec les tests d'adéquation et avec l'invariance de l'ordre, sinon l'interlocuteur retient *à flou* $\hat{z}$ au lieu de *à rigueur* $\hat{z}$.

26 VaR prédictive et VaR robuste

Le problème. La remarque de Caroline Hillairet : prendre un quantile d'un objet incertain est mauvais. Comment y répondre sans abandonner la VaR, qui est imposée ?

L'idée. Deux réponses différentes, à ne pas confondre. **La VaR prédictive** intègre l'incertitude de paramètre dans la loi elle-même : on mélange les lois sur la loi a posteriori des paramètres, puis on prend le quantile du mélange. **La VaR robuste** prend le pire cas sur un ensemble d'ambiguïté : on ne mélange pas, on borne.

La formule.

$$\text{VaR}_\alpha^{\text{préd}} = \text{VaR}_\alpha \left(\int f(\cdot | \theta) \pi(\theta) d\theta \right), \quad \text{VaR}_\alpha^{\text{rob}} = \sup_{\theta \in \Theta} \text{VaR}_\alpha(f(\cdot | \theta)).$$

Chez nous. Chaîne complète : point 659, prédictive 646, robuste à 95 % 1026, pire cas de modèle 1311. **La prédictive coïncide presque avec le plug-in** à 99,5 % (657 contre 659), ce qui est un résultat en soi : à ce niveau de quantile, l'intégration ne change presque rien, la fragilité est ailleurs.

À dire à voix haute. *Caroline a raison, et c'est mesurable. Ma réponse n'est pas d'abandonner la VaR, qui est imposée, mais de rendre l'incertitude visible sur trois étages. Et j'ai un résultat un peu contre-intuitif : la VaR prédictive coïncide presque avec la VaR ponctuelle. Ce n'est pas l'intégration qui manquait, c'est la largeur de bande qui est le vrai sujet.*

Le piège. Ne pas présenter la prédictive comme la bonne réponse qui remplacerait le plug-in. Elle règle un problème (l'incertitude de paramètre) et pas l'autre (l'ambiguïté de modèle). C'est la robuste qui règle le second, et les deux ne se substituent pas.

VIII. Les outils annexes

27 Le kappa de Cohen

Le problème. Deux codeurs lisent les mêmes récits. Comment mesurer leur accord, sachant que même deux personnes répondant au hasard seraient parfois d'accord par chance ?

La formule.

$$\kappa = \frac{p_o - p_e}{1 - p_e},$$

où p_o est l'accord observé et p_e l'accord attendu par pur hasard. $\kappa = 1$ est un accord parfait, $\kappa = 0$ un accord au niveau du hasard.

Chez nous. Seuil pré-enregistré : $\kappa \geq 0,60$ lève la réserve sur le codage. En dessous, c'est un résultat publiable en soi : cela signifierait que la séquence des défaillances n'est pas lisible de façon reproductible dans les rapports d'enquête.

À dire à voix haute. *Le kappa corrige l'accord du hasard. Deux personnes qui répondraient au hasard seraient d'accord une fois sur cinq : le kappa retranche cette part. Et j'ai fixé mon seuil avant de connaître le résultat, pour ne pas pouvoir l'ajuster après.*

28 La valeur d'information

L'idée. Une recommandation de reporting ne vaut rien tant qu'elle n'est pas chiffrée. On la chiffre en mesurant de combien la bande de capital rétrécit quand on acquiert l'information.

La formule. Avec $L(\mathcal{V}) = \sup_{\mathcal{V}} \text{SCR} - \inf_{\mathcal{V}} \text{SCR}$,

$$V(\mathcal{I}) = 1 - \frac{L(\mathcal{W}_{\mathcal{I}})}{L(\mathcal{W})} \in [0, 1].$$

Cette quantité est *monotone* (une information plus riche ne vaut pas moins) et *sans dimension* (donc comparable d'une source de sévérité à l'autre).

Chez nous. La lecture des sept rapports lève 66 % de l'ambiguïté. Et la valeur se **hiérarchise** : documenter la seule dépendance gouvernance vers incidents lèverait 28,9 % à elle seule, tandis que le lien tests vers prestataires n'en lèverait *rien*.

À dire à voix haute. *J'ai chiffré ce que vaut, en capital, une donnée qu'on n'a pas. Sept rapports publics lèvent deux tiers de l'ambiguïté. Et surtout un superviseur qui ne pourrait exiger qu'une seule chose sait laquelle exiger, parce que l'écart entre les dépendances est énorme.*

Le piège. Une bande subsisterait même les dix sens connus, imputable à la seule *amplitude*. L'identification partielle n'est pas un état provisoire que la donnée finirait par lever, elle est structurelle.

29 Le bayésien conjugué

L'idée. Plutôt que d'estimer un signe de direction par oui ou non, on lui attribue une probabilité, qu'on met à jour avec les observations documentaires.

La formule. Modèle Beta-binomial : si $\theta \sim \text{Beta}(\alpha_0, \beta_0)$ est la probabilité que la direction aille dans un sens, et qu'on observe n_{lo} transitions dans ce sens et n_{hi} dans l'autre, alors

$$\theta \mid \text{données} \sim \text{Beta}(\alpha_0 + n_{lo}, \beta_0 + n_{hi}),$$

et l'on pose $A = S(2\theta - 1)$, de sorte que $\theta = 1/2$ donne $A = 0$.

Chez nous. Médiane 8 127 M€, intervalle crédible [7 957 ; 8 316]. La sensibilité au prior est de 0,8 %, donc négligeable : les données dominent. Mais seulement 2 paires sur 6 ont un intervalle qui exclut 0,50, donc quatre restent indécises.

À dire à voix haute. *Le bayésien me permet de dire si ce lien va probablement dans ce sens z au lieu de trancher par oui ou non. Deux résultats : le prior n'a presque aucune influence, ce qui est rassurant, et seulement deux paires sur six sont réellement tranchées, ce qui est honnête.*

Le piège. Le bayésien ne crée pas d'information. Il exprime autrement la même incertitude, de façon plus lisible et plus fine, mais il ne remplace pas la donnée manquante.

Annexe : les vingt nombres à connaître par cœur

Nombre	Ce que c'est	Où
$\varphi = 9,2$	surdispersion de la fréquence	fréquence
$p \approx 10^{-30}$	rejet de Poisson contre NB	fréquence
$\xi = 0,60 / 1,03$	indice de queue OpRisk / PRC	sévérité
$u = 4,176 \text{ M€}$	seuil des excès	sévérité
$p_u = 0,150$	part des pertes au dessus du seuil	sévérité
$g = 0,90$	facteur de propagation	cascade
$\ A\ /\ W\ = 40,7 \%$	part directionnelle de la matrice	cascade
$K_4 = 1,033$	seuil de déclenchement de P4	cascade
$\lambda_U = 0,53$	dépendance de queue de Gumbel	dépendance
$0,17 \rightarrow 0,39$	co-extrême, gaussien vers Gumbel	dépendance
$119 \text{ vs } 128 \pm 27$	placebo OpRisk	identification
$z = -0,33$	placebo, bases agrégées	identification
$z = +3,93$	placebo, post-mortems	identification
$\sigma = 0,0700$	production d'entropie	identification
1024	sommets énumérés	identification
$5\,275 \text{ M€}$	socle sans contagion	capital
$[6\,858 ; 8\,697] \text{ M€}$	capital borné	capital
$p = 0,87$	tests d'adéquation	validation
$2,6 / 1,8 / 5,5$	les trois étages d'incertitude	validation
$66 \% / 28,9 \%$	valeur d'information, totale / meilleure paire	livrable

La phrase qui tient tout. Si l'on ne devait retenir qu'une chose de ce document : *le niveau de capital bouge dans une bande large, mais l'ordre des piliers ne bouge sous aucune des hypothèses testées.* C'est la thèse du mémoire, et c'est le seul énoncé qui survit aux trois étages d'incertitude.