

L'usage des bases : quelle source répond à quelle question

Fréquence et sévérité, ce que chacune peut porter et ce qu'elle ne peut pas

Kélian Kaddouri

3 août 2026

Le principe. On ne cherche pas *la* bonne base. Chaque source est utilisée pour la seule question qu'elle est capable de trancher, et l'on déclare ce qui reste hors d'atteinte. Cette note dit, brique par brique, quelle donnée alimente quel paramètre, à quel niveau d'observation, et avec quelle marge d'erreur. Elle contient aussi la réponse à la question posée sur la loi d'Erlang.

1. Trois sources, trois rôles disjoints

Source	Contenu	Ce qu'elle alimente
SAS OpRisk Global Data	pertes opérationnelles en dollars, catégories de Bâle, 4 329 transitions annuelles	le niveau de sévérité ($\xi = 0,595$) <i>et la fréquence d'entrée</i> . C'est la source porteuse.
Privacy Rights Clearinghouse	15 053 incidents, exprimés en <i>nombre d'enregistrements</i>	un axe de sensibilité sur la sévérité, après conversion Jacobs ($\xi = 1,033$, plafond 40 M€).
7 rapports post-incident	17 enchaînements codés	le sens des liens de contagion. Rien d'autre : ni volume, ni amplitude.

Deux bases publiques ont par ailleurs été testées et **écartées** : la Data Breach Chronology (manque de volume, taxonomie par vecteur d'attaque et non par domaine de contrôle, date piégée des deux côtés) et VCDB (le champ *actor.Partner* passe de 56 à 0 sur la période, artefact de collecte).

2. La sévérité

2.1. OpRisk, la source porteuse

Périmètre : secteur financier, sous-catégories TIC, pertes converties en euros. Le modèle n'ajuste que la queue, au dessus d'un seuil, par une loi de Pareto généralisée, et conserve le corps empirique en dessous. L'ajustement retient environ 91 excès au dessus du seuil, pour $\xi = 0,595$.

Ce chiffre est celui qui porte le capital principal, y compris le socle de 5 275 M€ et les bornes [6 858 ; 8 697] M€. **Il ne dépend d'aucune conversion** : les montants sont en dollars dès l'origine.

2.2. PRC, l'axe de sensibilité

PRC ne contient pas de montants mais des *nombre d'enregistrements compromis*. Le passage aux euros se fait par la régression de Jacobs, $\ln L = 7,68 + 0,76 \ln X + \varepsilon$, dont le résidu a un écart-type de 0,523.

Trois choses à savoir sur cette branche.

Elle donne $\xi = 1,033$, donc au dessus de 1 : la moyenne théorique de la sévérité n'existe pas. Ce n'est pas une anomalie de calcul, c'est une propriété du périmètre.

La conversion était traitée comme **exacte**, en ignorant le résidu, ce qui écrasait la dispersion. En le réinjectant, le niveau du Δ_{DORA} monte de 7% (3 600 $\rightarrow$ 3 861 M€) et la queue s'épaissit ($\xi : 1,033 \rightarrow 1,072$), mais la largeur relative de l'intervalle ne bouge pas (1,43 $\rightarrow$ 1,41).

Et la conversion est **de sévérité seule**. Ce n'est pas un lien fréquence-sévérité : elle transforme un décompte en montant, la fréquence venant d'ailleurs.

3. La fréquence : deux niveaux d'observation, deux paramètres

C'est le point méthodologique de cette note, et celui où une erreur serait la plus coûteuse. Le modèle de fréquence porte **deux** paramètres qui ne se lisent pas au même endroit :

$$N_j | Y \sim \mathcal{P}(\lambda_j m), \quad m = \exp\left(aY - \frac{a^2}{2}\right), \quad Y \sim \mathcal{N}(0, 1). \quad (1)$$

Le taux λ est une propriété d'**entité**. La charge systémique a est un choc **commun** à toutes les entités, tiré une fois par an.

Pourquoi les mélanger serait une faute. La surdispersion mesurée sur un panel firme-année est dominée par l'**hétérogénéité de taille** des firmes, pas par le choc commun : le panel mélange des TPE et des banques systémiques. Le choc commun ne se lit qu'au niveau **agrégué**, et seulement **après retrait de la tendance**, faute de quoi on confond une dérive séculaire avec de la volatilité annuelle.

3.1. Le taux par entité, lu sur le panel firme-année

Fenêtre 2005-2022. Au delà, les comptes s'effondrent (34 en 2023, 39 en 2024 contre 70 à 100 auparavant) : c'est la troncature à droite de la base, les événements récents n'étant pas encore remontés, et non une baisse du risque.

observations firme-année	14 944 (5 230 firmes)
moyenne empirique	0,0988 événement TIC / firme / an
variance empirique	0,1179
indice de dispersion Var/ $\mathbb{E}$	1,19
part de zéros	91,2 %
Poisson	$\log L = -5\,023,8$
Négative binomiale	$\log L = -4\,958,5$, forme $r = 0,632$
test du rapport de vraisemblance	LR = 130,5, $p = 1,6 \times 10^{-30}$

Le Poisson est rejeté sans ambiguïté. Et la sensibilité à la taille est forte : sur les seules firmes à dix événements ou plus, le taux passe de 0,099 à **0,210**, un profil plus proche d'une entité effectivement soumise à DORA.

3.2. Le choc systémique, lu sur la série agrégée détrendée

Sur la série sectorielle TIC agrégée (82 événements par an en moyenne sur 18 ans), la tendance ajustée vaut $-2,4\%$ par an, et la dispersion *résiduelle* après retrait de tendance vaut $\varphi = 2,24$, d'intervalle de confiance à 95 % [1,24 ; 5,18], large parce qu'il n'y a que 18 points.

La charge implicite correspondante est $a = 0,122$, d'intervalle [0,054 ; 0,223]. Sur le périmètre plus étroit cyber $\times$ finance (443 événements, 24,6 par an), la même lecture donne $a = 0,297$.

Le verdict, et il est à assumer tel quel. La valeur posée dans le modèle est $A_{\text{LOAD}} = 0,60$. Elle dépasse la charge empirique quel que soit le périmètre (0,12 ou 0,30), et elle dépasse même la **borne haute** de l'intervalle de confiance (0,223). Le calage n'est donc pas calibré, il est **délibérément conservateur**, et cette conclusion résiste à l'incertitude d'estimation.

4. La question de la loi d'Erlang

La loi mélangeante ajustée sur le panel est une Gamma de forme $r = 0,632$. Or :

Une Erlang	est une Gamma de forme entière ≥ 1 .
La forme ajustée	vaut 0,632 : ni entière, ni supérieure à 1.

L'Erlang la plus proche serait l'Erlang-1, c'est-à-dire un mélange exponentiel, mais ce n'est qu'une **approximation** : la Gamma réellement ajustée, de forme 0,63, est plus dissymétrique qu'une exponentielle.

À dire tel quel : le mélange Gamma est le bon objet, et l'Erlang n'en est qu'un cas particulier à forme entière. Ici la forme n'est pas entière, donc parler d'Erlang serait imprécis. La famille évoquée est la bonne, le nom ne l'est pas.

5. Les trois surdispersions, réconciliées

Le modèle porte trois représentations de la surdispersion, longtemps coexistantes sans avoir jamais été confrontées. Elles ne se contredisent pas, mais elles vivent à des **échelles différentes**, et c'est cela qu'il faut savoir dire.

Représentation	Échelle	Indice Var/ $\mathbb{E}$
mélange Gamma, $r = 0,63$	firme-année (micro, $\mu = 0,099$)	1,16
charge lognormale, $a = 0,60$	agrégée (portefeuille)	10,34
facteur négatif binomial, $\varphi = 9,20$	agrégée (portefeuille)	9,20

À l'échelle du moteur ($\lambda = 21,6$ amorces par an, soit 582 événements sur 27 ans), la correspondance entre les deux mesures agrégées se vérifie : $\varphi = 9,20$ implique $a = 0,568$ contre 0,60 posé, et $a = 0,60$ implique $\varphi = 10,34$ contre 9,20 posé. Elles **coïncident à 5 % près sur a** et à 12 % près sur φ : ce sont bien deux écritures de la même chose.

Le $r = 0,63$ du panel, lui, vit à l'échelle d'une *seule* firme et ne se compare pas directement aux deux autres. C'est le piège de lecture principal de cette brique.

Et le φ empirique est bien plus bas que le posé. Sur la série cyber $\times$ finance détrendée, la dispersion résiduelle vaut $\varphi = 3,27$, soit $\varphi \approx 3,0$ une fois remise à l'échelle du moteur, contre 9,20 retenu. Le calage est donc conservateur d'un facteur trois environ.

5.1. Ce que ce choix coûte, en capital

Loi de comptage	SCR (VaR 99,5 %)	Moyenne
Poisson ($\varphi \rightarrow 1$)	7 838 M€	1 019 M€
NB, $\varphi = 3,0$ (empirique détrendé)	7 981 M€	1 018 M€
NB, $\varphi = 9,20$ (posé)	8 553 M€	1 054 M€
NB, $\varphi = 10,3$ (équivalent $a = 0,60$)	8 534 M€	1 028 M€

Deux lectures. La **moyenne est invariante**, par construction, puisque $\mathbb{E}[N] = \lambda$ dans les quatre lois : ce que la surdispersion déplace, c'est la VaR, pas l'espérance. Et l'effet reste **modéré**, +9 % de Poisson au calage posé, parce qu'à 99,5 % la queue reste largement portée par une perte dominante de sévérité.

Enfin, à variance *égale*, la forme du mélange compte encore : le quantile 99,5 % du comptage vaut 74 sous un mélange Gamma et 82 sous un mélange lognormal, soit 11 % d'écart. **Apparier la variance n'apparie pas la queue.**

6. Pourquoi la fréquence est calibrable et la direction ne l'est pas

C'est la question qui revient, et la réponse est nette.

Calibrer la matrice de contagion W exige trois choses simultanément : un horodatage fin, une taxonomie par domaine de contrôle, et la **direction**. Or la direction tombe sous le test placebo ($z = -0,33$).

Calibrer une fréquence d'entrée n'exige **rien** de tout cela. Il suffit de savoir qu'un événement TIC est survenu chez telle entité telle année. Le pas annuel, fatal pour W , suffit parfaitement pour un comptage.

C'est un problème d'identification **strictement plus facile**, et c'est pourquoi les deux briques n'ont pas le même statut : la fréquence est confrontée à la donnée, la direction est bornée.

7. Les biais à déclarer

Le seuil de collecte. Le taux posé est de 12 à 22 incidents par an selon la brique, contre 0,099 à 0,210 observés par firme-année. L'écart n'est pas une erreur de calage : la base ne retient que les pertes **au dessus d'un seuil de collecte**. On calibre donc la fréquence des événements TIC *matériels*, générateurs de perte, qui est la bonne maille pour un modèle de capital, et non la fréquence de tous les incidents au sens du reporting DORA. Les deux nombres ne mesurent pas la même chose.

Le biais de taille. OpRisk sur-représente les grandes entités. Le taux de 0,210 sur les firmes à dix événements ou plus est le plus représentatif d'une entité soumise à DORA, et c'est celui qu'il faut citer.

La troncature à droite. Les deux dernières années de la base sont incomplètes. La fenêtre s'arrête donc à 2022, et il faut le dire avant qu'on ne s'étonne d'une baisse apparente du risque.

Le nombre de points. La charge systémique repose sur 18 observations annuelles. Son intervalle de confiance est large, d'un facteur quatre. C'est aussi pourquoi le calage conservateur est défendable : il n'est pas contredit par la donnée, il la borne par le haut.

En une phrase par brique. La **sévérité** vient d'OpRisk, en dollars, sans conversion, et PRC n'est qu'un axe de sensibilité. La **fréquence** se lit à deux niveaux, le taux sur le panel firme-année et le choc commun sur la série agrégée détrendée, et les mélanger serait une faute. Le calage retenu est **conservateur d'un facteur trois** sur la surdispersion, ce qui est un choix de prudence et non une calibration, et il déplace la VaR de +9 % sans toucher la moyenne. La **direction**, elle, ne se calibre sur aucune de ces bases, et c'est le seul paramètre du modèle qui reste borné plutôt qu'estimé.

Sources. Fréquence d'entrée : `2_donnees/08b_calibration_frequence_entree.py`, figure `N_frequence_entree.png`. Réconciliation des surdispersions et effet sur le SCR : `2_donnees/41_simulation_nb_comptage.py`, figure `N2_simulation_nb.png`. Faisabilité et écartement des sources : `2_donnees/05_faisabilite_donnees.py`. Résidu de la conversion Jacobs : `5_etats/21_prc_jacobs_residu.py`. Chapitre 5 du mémoire pour les données et leurs limites.