

Calibrer le facteur systémique des piliers DORA

En quoi la nouvelle méthode diffère de l'ancienne

Kélian Kaddouri

10 juillet 2026

Deux résultats, dans cet ordre. (1) L'estimateur de la contagion W que la note utilisait depuis le début comportait une **erreur d'indexation** : les indicatrices de période n'absorbaient rien. Elle est corrigée, et sa signature est instructive. (2) La généralisation A du modèle (un facteur systémique Y_j par pilier, des charges s_j , une matrice de dépendances croisées Σ_Y) était **posée sans protocole d'estimation**. Elle en a désormais deux, dont l'un ne requiert **aucune donnée individuelle**. Conséquence pour le mémoire : le verrou empirique est **plus étroit** que ne l'annonçait le chapitre de faisabilité.

1 Un bug d'indexation, et sa signature

1.1 L'erreur

Le probit du script 03 régresse l'incident du pilier j à la période t sur les incidents *retardés* des quatre autres piliers, avec des **effets fixes de période** destinés à absorber le systémique $s_j Y_{j,t}$. Le panel est aplati par `reshape(-1)` sur un tableau de forme $(N, T - 1)$, donc **ligne par ligne** : l'observation m est l'entité $m // (T - 1)$ à la période $m \bmod (T - 1)$.

```
per_idx = np.repeat(np.arange(T - 1), N)      # ANCIEN -- faux
per_idx = np.tile(np.arange(T - 1), N)        # NOUVEAU -- correct
```

Avec `repeat`, chaque indicatrice était collée à un bloc d'entités, pas à une période. Les effets fixes n'absorbaient **rien**.

1.2 Pourquoi la faute était invisible

Si $s_j Y_{j,t}$ reste dans le terme d'erreur, la variance de celui-ci passe de 1 à $1 + s_j^2$. Or un probit n'identifie ses coefficients qu'à *l'échelle de l'erreur près*. Tous les coefficients sont donc **atténués** du facteur

$$\frac{1}{\sqrt{1 + s_j^2}} = \frac{1}{\sqrt{1 + 0,5^2}} = 0,894. \quad (1)$$

La pente estimée valait 0,92. Elle *devait* valoir 1. Un écart de 8% vers le bas, sur un estimateur bruité : rigoureusement indiscernable d'un estimateur qui fonctionne. Le rapport observé après correction, $0,92/1,08 = 0,85$, est bien du bon ordre de grandeur que prédit l'atténuation.

Un estimateur qui rend le chiffre attendu n'est pas pour autant correct. Le bug ne produisait pas d'aberration : il produisait un résultat *plausible*. Il n'a été démasqué que par une tâche *ultérieure*, l'extraction de Y_j à partir de ces mêmes effets fixes, qui rendait $\text{corr}(\hat{Y}, Y) = 0,05$ et $\hat{s}_j \approx 0,04$ pour tous les piliers. C'est la tentative de faire la chose suivante qui a révélé l'erreur dans la chose précédente.

1.3 Ce que la correction déplace

La pente passe au-dessus de 1, comme le veut la théorie du probit : W est retrouvée **dans ses propres unités**, ce qui confirme au passage que l'estimateur naturel est un probit et non un logit

Table 1. Script 03, avant et après correction de l'indexation. Panel simulé $N = 800$ entités $\times T = 60$ périodes $\times 5$ piliers.

Diagnostic	Ancien (repeat)	Nouveau (tile)
Corrélation $\hat{W}$ vs W (probit)	0,83	0,92
Pente $\hat{W}$ sur W (probit)	0,92	1,08
Pente $\hat{W}$ sur W (logit)	1,83	2,11
Sens de l'asymétrie correctement retrouvé	–	100 %
Corrélation à $N = 400$	0,43	0,90
Asymétrie, panel réel	1,15	1,57
Asymétrie, après permutation (placebo)	0,39	0,38
Corrélation W avant / W temps inversé	–0,40	–0,70

(dont la pente 2,11 signale des magnitudes exprimées en unités logistiques). Et la puissance du protocole était très sous-estimée : $N = 400$ entités suffisent désormais, contre plusieurs milliers apparemment requis auparavant.

2 La nouvelle méthode : calibrer Y_j , s_j et Σ_Y

2.1 Ce que l'ancienne méthode ne faisait pas

La note posait la généralisation A,

$$X_{i,j,t} = \underbrace{\text{base}_j}_{\text{niveau}} + \underbrace{\sum_{k \neq j} W_{jk} D_{i,k,t-1}}_{\text{contagion dirigée}} + \underbrace{s_j Y_{j,t}}_{\text{systémique, propre au pilier}} + \varepsilon_{i,j,t}, \quad Y_t \sim \mathcal{N}(0, \Sigma_Y) \quad (2)$$

puis s'arrêtait là. **Aucun protocole n'était proposé pour Y_j , s_j , Σ_Y .** Le seul objet calibré était W . C'est le trou qui vient d'être comblé, par deux routes indépendantes.

2.2 Route A : lire les effets fixes qu'on avait déjà

Une fois l'indexation corrigée, les effets fixes de période du probit valent *exactement* $\varphi_{j,t} = \text{base}_j + s_j Y_{j,t}$. Il n'y avait rien à estimer de plus : il suffisait de les *lire*.

$$\text{base}_j = \overline{\varphi_{j,\cdot}}, \quad \hat{s}_j = \text{sd}_t(\varphi_{j,t}), \quad \hat{Y}_{j,t} = \frac{\varphi_{j,t} - \text{base}_j}{\hat{s}_j}, \quad \hat{\Sigma}_Y = \text{corr}(\varphi). \quad (3)$$

La dernière égalité tient parce qu'une corrélation est **insensible à l'échelle** s_j . Le prix à payer : la route A exige un panel *entité $\times$ pilier $\times$ période*.

2.3 Route B : la distance de Frobenius, sur données agrégées

Transposition directe de la méthode de Pineau et Zuñiga (2023, éq. 5), qui extraient leur facteur latent en minimisant la distance de Frobenius entre matrices de transition observées et engendrées. Ici, pour chaque période t , on n'observe que des **comptages agrégés** :

$$\Pi_{jk}^{\text{obs}} = \mathbb{P}(\text{incident en } j \text{ à } t \wedge \text{incident en } k \text{ à } t-1) \quad (25 \text{ moments}) \quad (4)$$

$$m_j^{\text{obs}} = \mathbb{P}(\text{incident en } j \text{ à } t) \quad (5 \text{ moments}) \quad (5)$$

et l'on résout, à W et base connues, un problème de 30 équations pour 5 inconnues $u_{j,t} = s_j Y_{j,t}$:

$$\hat{u}_t = \arg \min_{u \in \mathbb{R}^5} \left\| \Pi^{\text{obs}} - \Pi^{\text{mod}}(u) \right\|_F^2 + \omega^2 \left\| m^{\text{obs}} - m^{\text{mod}}(u) \right\|^2, \quad \omega = 3. \quad (6)$$

Les moments du modèle s'obtiennent en énumérant les $2^5 = 32$ configurations possibles d'incidents à $t-1$, sous indépendance des piliers à la période retardée.

Les moments marginaux sont indispensables, et c'est un piège coûteux. Ma première version n'utilisait que les 25 co-incidences. Elle rendait $\text{corr}(\hat{Y}, Y) = 0,835$ et sur-estimait $\hat{s}_j$ du *double*. J'ai d'abord cru au bruit d'échantillonnage : le fractionnement d'échantillon ne corrigeait rien (0,697 contre 0,694), donc le biais était **commun aux deux moitiés** : il était structurel, pas aléatoire. Diagnostic : le résidu corrélait à $+0,36$ avec le systémique retardé Y_{t-1} , parce que les co-incidences ne portent que sur les $\approx 6\%$ d'entités ayant déjà subi un incident en $t - 1$. u_j y est faiblement identifié et absorbe une part du systémique passé. Ajouter les 5 **incidences marginales**, qui, elles, portent sur 100 % de l'échantillon, fait passer $\text{corr}(\hat{Y}, Y)$ de 0,835 à 0,969.

2.4 Résultats

Table 2. Restitution du facteur systémique. Panel simulé $N = 1200$, $T = 70$, incidence moyenne 6,2 %. Vérité : $s = (0,35, 0,55, 0,45, 0,60, 0,30)$, $\text{base}_j = -1,70$.

Route	$\hat{s}_j$ par pilier					$\overline{\text{corr}(\hat{Y}, Y)}$
	P1	P2	P3	P4	P5	
Vérité	0,35	0,55	0,45	0,60	0,30	—
A, panel individuel	0,384	0,502	0,469	0,660	0,304	+0,981
B, comptages agrégés	0,384	0,502	0,470	0,745	0,304	+0,969

Les niveaux sont retrouvés à base $= (-1,71, -1,79, -1,71, -1,75, -1,75)$ contre $-1,70$. L'erreur absolue moyenne hors-diagonale sur Σ_Y vaut 0,095 (route A) et 0,093 (route B).

N : le systémique se calibre sur données AGREGÉES, la contagion non




Figure 1. Le facteur systémique par pilier est restitué par les deux routes. (a) série temporelle du pilier P4, celui de plus forte charge ; (b) corrélation pilier par pilier ; (c) les dépendances croisées Σ_Y , estimées contre vraies.

3 Ancienne méthode contre nouvelle méthode

Table 3. Ce qui a changé.

Objet	Ancienne méthode	Nouvelle méthode
Effets fixes de période	Mal indexés (repeat) : n’absorbaient rien. Le systémique polluait l’erreur.	Correctement indexés (tile) : ils absorbent le systémique <i>et</i> le mesurent.
Échelle du probit	Atténuée de 0,894 sans qu’on le sache. Pente 0,92.	Non atténuée. Pente 1,08 : W dans ses propres unités.
Charges s_j	Non estimées. Postulées.	Estimées : écart-type temporel des effets fixes.
Facteur $Y_{j,t}$	Non estimé. Objet purement théorique.	Restitué à corr = 0,98 (A) ou 0,97 (B).
Dépendances Σ_Y	Non estimées.	Corrélation des effets fixes ; erreur $\approx 0,09$.
Donnée requise pour le systémique	(question non posée)	Comptages agrégés par pilier et par période. Aucun identifiant d’entité.
Donnée requise pour W	Panel individuel horodaté	Panel individuel horodaté au mois (<i>inchangé : introuvable, cf. script 05</i>)

4 Ce que cela change pour le mémoire

Le verrou est plus étroit qu’annoncé, et c’est un résultat positif. Le chapitre de faisabilité concluait que le modèle n’était pas calibrable sur les sources disponibles. Cette conclusion vaut pour W , et pour W seulement. La route B n’utilise **aucun identifiant d’entité** : uniquement des comptages agrégés par pilier et par période. Or c’est précisément ce que publient déjà les registres DORA, l’ENISA et les CERT.

Objet du modèle	Donnée requise	Disponible ?
Contagion dirigée W	panel individuel horodaté au mois	non
Y_j, s_j, Σ_Y	statistiques agrégées publiques	oui

Autrement dit : la **généralisation A**, un facteur systémique par pilier avec ses charges et ses dépendances croisées, ce qui est déjà une rupture nette avec le Vasicek à un facteur, est calibrable **dès aujourd’hui**, sur données publiques. Seule la **généralisation B**, la contagion dirigée, attend sa donnée. Le chapitre négatif devient un chapitre à deux régimes.

5 Limites, dites franchement

Trois réserves qu'il ne faut pas laisser sous silence.

1. **Tout ceci est établi sur données simulées.** Le processus générateur est connu, donc les deux routes sont validées contre une vérité que l'on possède. C'est une preuve de correction de l'estimateur, **pas** une preuve que le modèle décrit le monde.

2. **La route B suppose W et base connues.** Elle extrait le systémique *conditionnellement* à la contagion. Comme W n'est pas calibrable, il faudra en pratique la balayer sur le gain admissible $g \in (0, 1]$ et vérifier que $\hat{Y}$ est stable. Cette vérification n'est pas faite.

3. **Σ_Y est le maillon faible.** L'erreur absolue moyenne de 0,09 paraît bonne, mais la corrélation entre les dix coefficients hors-diagonale vrais et estimés ne vaut que 0,67. On retrouve le *niveau* des dépendances croisées, pas finement leur *structure*. Sur $T = 70$ périodes, c'est un problème d'échantillon, et il faut le dire. Le pilier P4 en porte la trace : $\hat{s}_4 = 0,745$ contre 0,60 par la route B.

Reproductibilité

Script	Produit
03_calibration_W.py	figures K1, K2, K3 ; indexation corrigée
06_facteur_systemique.py	figure N ; routes A et B

Graine 20260710. Dépendances : `numpy`, `scipy`, `statsmodels`, `matplotlib`. Référence : Pineau, É. et Zuñiga, F. (2023), pour la méthode d'extraction de facteur par distance de Frobenius.